



Synthèse de la baseline BTGenBot

Claude Opus 4.8 face aux modèles du papier

Benjamin Lepourtois Anne Faury Mohamed Amar

Mourad Latoundji

3 juin 2026

NAV4RAIL



Protocole d'évaluation

Métriques

Comparatif complet

Synthèse et bilan

Jeu d'évaluation : les 9 tâches standardisées du papier BTGenBot (Izzo 2024), et non le dataset d'entraînement de 594 paires.

ID	Tâche	Complexité
T1	Navigation simple	★
T2	Navigation avec priorité	★★
T3	Navigation avec fallback	★★
T4	Navigation + bras manipulateur	★★
T5	Exploration autonome	★ ★ ★
T6	Exploration + manipulateur	★ ★ ★
T7	Vision active + saisie	★ ★ ★ ★
T8	Traitement de matériaux	★ ★ ★ ★
T9	Assemblage multi-stations	★ ★ ★ ★

Source commune

Les descriptions NL et les BTs de référence proviennent du même référentiel :

```
external/BTGenBot/  
bt_generator/config/  
example_retrieving.yaml
```

Point clé

Les sorties FT du papier étaient déjà publiées dans le dépôt GitHub officiel BTGenBot. Elles ont donc été réévaluées avec notre pipeline commun.

Zero-shot / One-shot

Zero-shot : instructions système + description de tâche.

One-shot : même entrée, plus un exemple fixe T1.

T1 reste évaluée en zero-shot pour éviter de fournir sa propre réponse.

Pipeline d'évaluation

1. Génération du BT XML
2. Vérification syntaxique
3. Calcul Node-F1 et TED
4. Jugement binaire « Correct / Incorrect » par Claude Opus 4.8

Rigueur de comparaison

Les configurations Opus 4.8 et les sorties FT du papier sont comparées sur un pipeline commun.

Protocole d'évaluation

Métriques

Comparatif complet

Synthèse et bilan

Syntaxe

XML valide : le XML est parseable.

Structure BT valide : présence de `<root>` et de `<BehaviorTree>`.

Limite connue

Ce contrôle est moins strict que Groot2 : il ne valide ni toute la palette de nœuds, ni les paramètres ROS2.

Sémantique

Node-F1 : proximité des types de nœuds.

TED : distance structurelle entre arbres.

LLM-as-Judge : adéquation description ↔ BT.

Lecture

Node-F1 et TED comparent au BT de référence. Le juge évalue la correspondance à la description.

Définition : F1-score calculé sur le multiset des **types de nœuds** du BT généré vs le BT de référence.

Nœuds exclus : root, BehaviorTree, TreeNodesModel, input_port, output_port, inout_port.

$$\text{Precision} = \frac{|N_{pred} \cap N_{ref}|}{|N_{pred}|} \quad \text{Recall} = \frac{|N_{pred} \cap N_{ref}|}{|N_{ref}|}$$

$$\text{Node-F1} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Interprétation

La métrique récompense le bon choix des nœuds métier et leur proportion, pas seulement une structure XML valide.

BT de référence

```
<BehaviorTree>
  <Sequence>
    <MoveTo .../>
    <ActivateManipulator/>
  </Sequence>
</BehaviorTree>
```

BT généré

```
<BehaviorTree>
  <Sequence>
    <Action .../>
    <Action .../>
  </Sequence>
</BehaviorTree>
```

Multiset	Types
N_{ref}	{Sequence : 1, MoveTo : 1, ActivateManipulator : 1}
N_{pred}	{Sequence : 1, Action : 2}
$N_{ref} \cap N_{pred}$	{Sequence : 1}

$$\text{Precision} = \frac{1}{3} \quad \text{Recall} = \frac{1}{3}$$

$$\text{Node-F1} = 0.333$$

Lecture : la structure `Sequence` est correcte, mais les nœuds métier ont été remplacés par un `Action` générique.

TED (Tree Edit Distance) est la distance de Zhang-Shasha entre deux arbres ordonnés.

- Elle compte le nombre minimal d'opérations nécessaires pour transformer le BT généré en BT de référence.
- Les opérations sont : insertion, suppression, renommage de nœud.
- **TED = 0** signifie un arbre identique ; plus la distance augmente, plus l'écart structurel est important.

Interprétation

$TED \leq 3$: BT structurellement proche.

$TED > 10$: structure significativement différente.

Arbre de référence

Sequence

/

MoveTo ActivateManipulator

Arbre généré

Sequence

/

Action Action

1. Renommer Action $\rightarrow$ MoveTo
2. Renommer Action $\rightarrow$ ActivateManipulator

Résultat

Deux opérations suffisent, donc **TED = 2**.

Définition : un juge reçoit la description en langage naturel et le BT XML généré, puis répond seulement Correct ou Incorrect.

Prompt du juge

Given a description of a behavior tree in natural language and a BT in XML format, say if the description matches the tree. Output only Correct or Incorrect.

Choix du juge

Claude Opus 4.8 est utilisé comme juge unique pour toutes les configurations.

Pourquoi pas Haiku ?

Haiku produisait des faux négatifs sur des cas limites sémantiquement valides ; Opus s'est montré plus cohérent.

Protocole d'évaluation

Métriques

Comparatif complet



Synthèse et bilan

Comparatif complet sur un même référentiel


Modèle	Mode	XML	BT	Node-F1	TED	Judge Opus	Éval. papier
Opus 4.8 v4_action_aware	ZS	100	100	0.812	3.1	66.7	—
Opus 4.8 v4_action_aware	OS	100	100	0.781	3.3	77.8	—
Opus 4.8 v1_paper	OS	100	100	0.733	4.7	88.9	—
Opus 4.8 v1_paper	ZS	100	100	0.538	6.0	77.8	—
CodeLlama 7B FT	OS	89	89	0.325	7.2	12.5	33.3
LlamaChat 7B FT	OS	100	89	0.254	10.6	22.2	44.4
LlamaChat 7B FT	ZS	89	78	0.110	12.9	12.5	0.0
CodeLlama 7B FT	ZS	67	67	0.102	9.8	33.3	0.0
ChatGPT (papier)	ZS	100	—	—	—	—	77.8
Gemini (papier)	ZS	88.9	—	—	—	—	55.6
LLaMA-2-13B (papier)	ZS	33.3	—	—	—	—	22.2

XML et BT sont exprimés en %. Les colonnes Node-F1, TED et Judge Opus ne sont tracées que lorsqu'une réévaluation complète avec notre pipeline est possible.

Vue graphique : Node-F1 et TED



Vue graphique : jugement observé



Protocole d'évaluation

Métriques

Comparatif complet

Synthèse et bilan

Ce que montrent les résultats

- Opus 4.8 produit du XML exploitable à 100% sur toutes nos configurations.
- `v4_action_aware` zero-shot donne le meilleur alignement structurel avec la référence.
- Le one-shot aide surtout `v1_paper`, pas `v4_action_aware`.

Lecture des modèles FT

- Les 7B fine-tunés du papier restent très loin d'Opus 4.8.
- Le fine-tuning observé ici ne fournit pas un concurrent crédible pour la meilleure performance brute.
- Cela ne prouve pas qu'aucun FT futur ne dépassera Opus 4.8 ; cela montre seulement que ce n'est pas le cas avec les résultats disponibles.

Message principal

Si l'objectif prioritaire du projet est **la meilleure performance de génération**, la décision la plus rationnelle est de conserver Claude Opus 4.8 comme référence opérationnelle.

- **Baseline recommandée** : v4_action_aware zero-shot comme référence principale, et v1_paper one-shot comme point de comparaison côté juge.
- **Quand fine-tuner ?** seulement si l'objectif devient coût, latence, embarqué, souveraineté ou contrôle plus fin du modèle.
- **Conclusion défendable** : avec les évidences actuelles, rien ne justifie de quitter Opus 4.8 si le seul critère est la performance brute.