



BTGenBot × NAV4RAIL

Semaine 1 — EDA et préparation du dataset

Benjamin Lepourtois Anne Faury Mohamed Amar
Mourad Latoundji

28 mai 2026

Mastère spécialisé IA/DATA — Promotion 2026



Plan de travail et posture

Dataset et chiffres clés

Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Objectifs annoncés :

- Téléchargement dataset BTGenBot
- EDA : catégories, longueur BTs, vocabulaire nœuds
- Conversion JSONL + adaptation prompt

Livrable concret :

- 1 notebook synthèse unifié
- Dataset SFT-ready
- Rapports MD + figures réutilisables

Posture méthodologique

Fidélité maximale au papier
BTGenBot (Izzo 2024).

Le papier ne mentionne aucun filtrage, le repo officiel ne livre pas le script d'entraînement.

On garde les **594 exemples bruts**, on documente tout le reste.

Plan de travail et posture

Dataset et chiffres clés

Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Source :

- Dépôt officiel
AIRLab-POLIMI/BTGenBot
- `dataset/bt_dataset.json`, 2.2 MB
- Diff byte-à-byte vs fichier local → identique

Format : Alpaca

- `instruction` (consigne système)
- `input` (description NL de la tâche)
- `output` (Behavior Tree en XML)

Volume : 594 paires (papier annonce
~600)

Origine des BTs

Behavior Trees extraits de projets ROS2 open-source (Nav2, ROBORTS, etc.).

Descriptions NL générées par GPT-3.5-turbo à partir des BTs.


⇒ Dataset **semi-synthétique**.

Métrique	Valeur
Total exemples	594
XML valides (parse strict)	578 (97.31%)
XML valides (cleaning étendu)	571 (96.13%)
Longueur input (mots), médiane	117
Longueur input (mots), p95	158
Longueur XML (chars), médiane	1 080
Longueur XML (chars), p95	11 878
Longueur XML (chars), max	31 681
Nb nœuds BT, médiane / max	15 / 399
Profondeur BT, médiane / max	5 / 21
Tags XML uniques	360
Skills métier uniques	1 223
Variables blackboard {var} uniques	296

Lecture

- Inputs **très homogènes** (médiane 117 mots, p95 158)
- XML **très asymétrique** : médiane 1k chars, max 31k
- Arbres variés : 15 nœuds typique, jusqu'à 399 (Nav2 cascadié)
- **1 223 skills uniques** = vocabulaire ouvert (vs catalogue fermé SNCF, 28 skills)

Longueurs : input vs output XML



Input : distribution **gaussienne resserrée** (prompt court généré uniformément par GPT-3.5). Output : distribution **log-normale** avec longue traîne — quelques BTs Nav2 monstrueux dominant les statistiques.

Plan de travail et posture

Dataset et chiffres clés

Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Distribution des erreurs :

Type d'erreur	Count
Token invalide (commentaires <code><!--></code> malformés, attributs sans guillemets)	12
Tag non fermé / mal fermé	4
Total invalides	16 (2.7%)

Origine : bugs de génération
GPT-3.5 — XML « presque valide ».
Cohérent avec dataset
semi-synthétique.


Décision

Dataset conservé à 594 entiers.

Le papier ne filtre pas. SFTTrainer apprend du texte, ne valide pas le XML. Les 16 invalides (2.7%) seront appris comme texte ordinaire — bruit négligeable.

On documente, on filtre pas.

Structure des Behavior Trees



La plupart des BTs sont **petits à moyens** (médiane 15 nœuds, profondeur 5) mais quelques arbres atteignent 399 nœuds et 21 niveaux — scénarios Nav2 complets avec recovery cascadé.

Plan de travail et posture

Dataset et chiffres clés


Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Catégories descriptives — méthode hybride



Méthode : signal XML (skills présents) prioritaire, fallback regex sur input texte. 5 catégories canoniques.

Flag transverse `has_recovery_pattern` = présence de `Fallback/RecoveryNode` avec `Sequence` imbriquée : **224 / 594** BTs (37.7%), concentrés sur navigation (44% des BTs nav).

Distribution :

Catégorie	%
navigation	73.1%
other	16.8%
manipulation	7.2%
perception	2.5%
exploration	0.3%

NAV4RAIL = navigation + perception


SNCF = inspection ferroviaire.

Dataset BTGenBot **bien aligné navigation** (73%) mais **faible perception** (15 exemples, 2.5%).

⇒ Mauvaise nouvelle pour le transfert direct sur les skills perception du catalogue SNCF.

Le modèle apprendra solidement les patterns Nav2 mais aura peu de signal pour la capture / analyse visuelle propres à l'inspection.

Recovery patterns — Top motifs Nav2



Top patterns : `Fallback(Condition, Action)` (31), `RecoveryNode(FollowPath, ClearEntireCostmap)` (26), `RecoveryNode(ComputePathToPose, ClearEntireCostmap)` (21).

⇒ Signature canonique du recovery Nav2 (« essayer planifier, sinon nettoyer costmap »). Le modèle apprendra surtout la **syntaxe** de ces motifs BT, pas leur sémantique métier. Pour NAV4RAIL, ces patterns 2D ne sont pas transférables tels quels : seule l'idée générale d'une séquence corrective res

Plan de travail et posture

Dataset et chiffres clés


Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Tokenization — diagnostic critique vs papier



Papier fixe `max_seq_length=4096` sans documenter la distribution. **Notre mesure** : Llama-3.1 et Qwen2.5 quasi-équivalents (ratio médian = 1.000). Troncature à 4096 : 2.0–2.4%. $\Rightarrow$ On garde 4096 (fidélité), on documente le taux. Ablation 8192 si VRAM le permet en QLoRA.

Plan de travail et posture

Dataset et chiffres clés

Validité XML et structure

Catégorisation et recovery patterns

Token count

Synthèse

Livrables produits :

- 1 notebook synthèse unifié
(`eda_BT_synthesis_Benjamin.ipynb`)
- 2 JSONL trainables (chat + Alpaca)
- 8 figures PNG (`dataset/figs/`)
- 5 tables CSV + 7 rapports MD
- 1 smoke test set (15 BTs)
- 1 fichier `prompts.json` (v1 + v2)

Apports vs papier :

- Distribution token explicite (papier muet)
- Catégorisation hybride XML+texte
- Recovery patterns à profondeur 3
- Diagnostic transfert SNCF chiffré

Prochaine étape — semaine 2

Fine-tuning SFT QLoRA sur cluster
Télécom Paris (RTX 3090).

3 modèles :

- Llama-3.1-8B-Instruct
- Qwen2.5-7B-Instruct
- Qwen2.5-Coder-7B-Instruct

Config papier : LoRA $r=8/\alpha=16$, 70–80
epochs, `max_seq` 4096.

⇒ Dataset prêt, code de loading direct
via `datasets.load_dataset`.